

Uniwersytet Warszawski

Wydział Filozofii

Dominik Kostecki

Nr albumu: 460552

**Techniki perswazyjne w polskim dyskursie
parlamentarnym: anotacja manualna a kla-
syfikacja modeli językowych**

Praca roczna

na kierunku studiów Filozofia

Praca wykonana pod kierunkiem:

dr Marcin Będkowski

Wydział Filozofii UW

Warszawa, Sierpień 2026

Streszczenie

Praca bada, w jakim stopniu współczesna taksonomia technik perswazyjnych, opracowana na potrzeby zadania BSNLP 2025, koresponduje z tradycyjnymi kategoriami logicznymi - fallacjami i schematami argumentów - oraz jak sprawdza się w pilotażowej analizie pojedynczego wystąpienia z polskiej debaty sejmowej. Większość technik BSNLP ma bezpośredni odpowiednik wśród klasycznych błędów wnioskowania, choć kilka z nich, na przykład slogany czy powtórzenie, pozostaje bliższe retoryce niż logice.

Pełne wystąpienie sejmowe poddano sekwencyjnej anotacji manualnej, a uzyskane wyniki porównano z klasyfikacją czterech modeli językowych. Modele nie pominęły żadnego akapitu ocenionego w anotacji referencyjnej jako perswazyjny, ale wykazały wyraźną skłonność do wskazywania technik w treściach czysto informacyjnych oraz do nadmiarowego stosowania etykiety nacechowanego emocjonalnie słownictwa (*Loaded Language*) kosztem etykiet wymagających głębszej integracji kontekstu.

Słowa kluczowe

fallacje, schematy argumentów, techniki perswazyjne, BSNLP, modele językowe, dyskurs publiczny

Spis treści

Wstęp	4
1. Wprowadzenie	5
1.1. Rys historyczny i klasyfikacja błędów logicznych	5
1.2. Schematy argumentów Waltona	5
1.3. Pragmatyka języka: maksymy Grice’a	6
1.4. Taksonomia BSNLP	7
2. Analiza empiryczna	8
2.1. Materiał i metodologia badawcza	8
2.2. Wyniki anotacji manualnej	8
3. Analiza modeli językowych	11
3.1. Metodologia	11
3.2. Porównanie wyników z anotacją referencyjną	12
Podsumowanie	14
Bibliografia	16

Wstęp

Współczesny dyskurs publiczny - kreowany przez polityków, dziennikarzy i komentatorów - jest nasycony próbami przekonania odbiorcy do określonych racji. Obok rzetelnej argumentacji regularnie pojawiają się w nim błędy logiczne i chwytły erystyczne. Choć logika bada te zjawiska od czasów starożytnych, współcześnie, pod pojęciem technik perswazyjnych, stanowią one również przedmiot intensywnych badań w dziedzinie przetwarzania języka naturalnego (NLP).

Celem pracy jest sprawdzenie, na ile poszczególne techniki z taksonomii zadania BSNLP 2025 (formalnie: SlavicNLP 2025 Shared Task) da się powiązać z klasycznymi fallacjami i schematami argumentacyjnymi, a na ile są to kategorie bez odpowiednika w tradycji logicznej. Zbadane zostanie też, jak ta taksonomia - opracowana z myślą o materiale wielojęzycznym - sprawdza się w praktyce przy pilotażowej analizie pojedynczego, w pełni zanotowanego wystąpienia z polskiej debaty sejmowej.

1. Wprowadzenie

1.1. Rys historyczny i klasyfikacja błędów logicznych

Pytanie o to, co odróżnia dobry argument od złego, jest tak stare jak sama logika. Arystoteles w traktacie *O dowodach sofistycznych* opisał trzynaście rodzajów pozornych, sofistycznych obaleń¹: sześć z nich zależy od dwuznaczności języka, w jakim sformułowano argument (jak ekwiwokacja czy amfibolia), pozostałe siedem zależy od samej struktury rozumowania, jak *petitio principii*, czyli błędne koło polegające na zakładaniu tego, co dopiero ma zostać udowodnione, oraz fałszywa przyczyna. Przez kolejne stulecia ten katalog pozostawał w logice na marginesie, traktowany raczej jako dydaktyczna ciekawostka niż osobny przedmiot badań. Zmieniła to dopiero książka C.L. Hamblina *Fallacies* z 1970 roku², w której autor pokazał, że podręcznikowe ujęcie błędów logicznych - powielane od wieków bez większych zmian i nazwane przez niego *standard treatment* - nie proponuje w istocie spójnej definicji fallacji, a jedynie zestaw przykładów bez łączącej je teorii. Krytyka Hamblina otworzyła nowy etap badań nad argumentacją, kontynuowany między innymi przez Teresę Hołówkę, która w podobnym duchu porządkowała typowe błędy argumentacyjne pojawiające się w codziennych sporach, choć bez tak rozbudowanego aparatu teoretycznego³.

Fallacje dzieli się zwykle na formalne, polegające na naruszeniu reguł logiki formalnej niezależnie od treści argumentu, oraz nieformalne, zależne od treści i kontekstu, w jakim argument padł. Fallacje nieformalne stanowią zdecydowaną większość błędów opisywanych w literaturze przedmiotu i to im poświęcona jest dalsza część tej pracy.

1.2. Schematy argumentów Waltona

Jedną z odpowiedzi na krytykę Hamblina jest koncepcja Douglasa Waltona, który zamiast katalogować błędy jako osobną kategorię, opisał najpierw ogólne wzorce rozumowania powszechnie stosowane w codziennej argumentacji - schematy argumentów (*argumentation*

¹Arystoteles. 1990. *O dowodach sofistycznych*. Warszawa: Wydawnictwo Naukowe PWN

²Hamblin, Charles Leonard. 1970. *Fallacies*. London: Methuen

³Hołówka, Teresa. 1998. *Błędy, spory, argumenty: szkice z logiki stosowanej*. Warszawa: Wydział Filozofii i Socjologii Uniwersytetu Warszawskiego

schemes). Wraz z Christopherem Reedem i Fabrizio Macagno skatalogował ich 96⁴, między innymi odwołanie do opinii eksperta, odwołanie do popularności danego poglądu czy argument ze skutków. Każdemu schematowi towarzyszy zestaw pytań krytycznych: dla odwołania do opinii eksperta należy na przykład sprawdzić, czy przywoływana osoba rzeczywiście jest ekspertem w danej dziedzinie i czy wypowiada się w granicach swoich kompetencji. Błąd, w tym ujęciu, pojawia się dopiero wtedy, gdy takie pytania są ignorowane albo nie da się na nie odpowiedzieć twierdząco - odwołanie do autorytetu samo w sobie nie jest więc fallacją, staje się nią dopiero przy nieuczciwym użyciu. To rozróżnienie jest istotne dla dalszej części pracy: część technik perswazyjnych z taksonomii BSNLP omówionej w kolejnym podrozdziale da się opisać właśnie jako nieuczciwe zastosowanie skądinąd neutralnych schematów argumentacyjnych.

1.3. Pragmatyka języka: maksymy Grice'a

Szczególne znaczenie dla analizy technik perswazyjnych ma pragmatyka języka, w tym koncepcja Paula Grice'a. Grice sformułował fundamentalną zasadę kooperacji, nakazującą uczestnikom rozmowy wносить do niej taki wkład, jaki jest wymagany przez aktualny cel i kierunek wymiany zdań⁵. Zasadę tę rozkłada on na cztery maksymy konwersacyjne: maksymę jakości (mów prawdę i nie twierdź tego, czego nie potrafisz uzasadnić), maksymę ilości (mów tyle, ile trzeba, nie więcej i nie mniej), maksymę odniesienia (mów na temat) oraz maksymę sposobu (wyrażaj się jasno i unikaj niejednoznaczności). Zwrócił on uwagę, że nieuczciwa perswazja w naturalnych rozmowach rzadko przybiera formę czystego błędu w dowodzie logicznym; znacznie częściej opiera się na tym, co zostaje zaimplikowane poprzez pozorne złamanie jednej z tych maksym przy jednoczesnym założeniu, że rozmówca wciąż współpracuje - tak powstaje implikatura konwersacyjna, czyli treść, którą wypowiedź komunikuje, choć nie została w niej dosłownie wyrażona. Podobnie działają presupozycje, czyli treści milcząco zakładane przez zdanie: pytanie w rodzaju „Od kiedy przestaliście okradać budżet państwa?” zakłada, że okradanie budżetu miało miejsce, a samo zaprzeczenie odpowiedzi na to pytanie nie pozwala tego założenia podważyć. Taka perspektywa pozwala znacznie precyzyjniej uchwycić naturę współczesnej nieuczciwej perswazji w dyskursie politycznym niż odwołanie się wyłącznie do klasycznych błędów wnioskowania.

⁴Walton, Douglas N., Christopher Reed, i Fabrizio Macagno. 2008. *Argumentation Schemes*. Cambridge: Cambridge University Press

⁵Grice, H. Paul. 1975. Logic and Conversation. W *Speech Acts*, red. Peter Cole i Jerry L. Morgan, 3:41–58. Syntax and Semantics. New York: Academic Press

1.4. Taksonomia BSNLP

W ramach zadania SemEval-2023 Task 3 wyodrębniono dwadzieścia trzy techniki propagandowe, badane w dziewięciu językach, w tym polskim⁶. Zadanie BSNLP 2025, stanowiące główny punkt odniesienia niniejszej pracy, rozszerzyło tę listę o dwie kolejne techniki (łącznie dwadzieścia pięć). Klasyfikacja ta dotyczy analizy tekstów z debat parlamentarnych oraz mediów społecznościowych w pięciu językach słowiańskich, włączając w to polski⁷. Wyróżnione techniki zgrupowano w sześciu kategoriach: atak na reputację, uzasadnienie, uproszczenie, odwrócenie uwagi, wezwanie do działania oraz manipulacyjne słownictwo.

Kategoria logiczna	Technika BSNLP
Ad hominem	Name Calling, Guilt by Association, Casting Doubt
Odwołanie do autorytetu	Appeal to Authority
Odwołanie do strachu / litości	Appeal to Fear Prejudice, Appeal to Pity
Fałszywy dylemat	False Dilemma or No Choice
Zarzut hipokryzji	Appeal to Hypocrisy, Whataboutism
Naruszenie maksym Grice’a	Loaded Language, Exaggeration or Minimisation
Brak wyraźnego odpowiednika	Slogans, Repetition, Appeal to Time

Większość technik uwzględnionych w taksonomii BSNLP znajduje swoje odzwierciedlenie w klasycznych błędach we wnioskowaniu. Część z nich jednak - jak slogany czy repetycja - nie ma bezpośrednich odpowiedników w tradycyjnych katalogach logiki, ponieważ stanowią one raczej strategie retoryczne i erystyczne niż błędy ściśle argumentacyjne.

⁶Piskorski, Jakub, Nicolas Stefanovitch, Giovanni Da San Martino, i Preslav Nakov. 2023. SemEval-2023 Task 3: Detecting the Category, the Framing, and the Persuasion Techniques in Online News in a Multi-lingual Setup. W *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, 2343–2361. Toronto, Canada: Association for Computational Linguistics

⁷Piskorski, Jakub, Dimitar Dimitrov, Filip Dobranić, Marina Ernst, Jacek Haneczok, Ivan Koychev, Nikola Ljubešić, et al. 2025. SlavicNLP 2025 Shared Task: Detection and Classification of Persuasion Techniques in Parliamentary Debates and Social Media. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*. Vienna, Austria: Association for Computational Linguistics

2. Analiza empiryczna

2.1. Materiał i metodologia badawcza

Przedmiotem analizy był jeden kompletny dokument pochodzący z próbnych danych BSNLP 2025 dla języka polskiego⁸: stenogram wystąpienia posłanki Katarzyny Kotuli, wygłoszonego w Sejmie 11 kwietnia 2024 roku w ramach uzasadniania projektu ustawy o aborcji. Tekst podzielono na osiemnaście akapitów (P01-P18), zgodnie z podziałem obecnym w oryginalnym dokumencie, i poddano je sekwencyjnej anotacji. Proces ten przeprowadzono sekwencyjnie, bez uprzedniego filtrowania fragmentów o największym natężeniu retorycznym, co jest zgodne z praktyką tworzenia korpusów referencyjnych w zadaniach BSNLP.

Anotację przeprowadzono z wykorzystaniem środowiska LabelStudio uruchomionego lokalnie. W odniesieniu do każdego akapitu weryfikowano, czy dany fragment zawiera techniki perswazyjne, a w przypadku odpowiedzi twierdzącej - które z dwudziestu pięciu technik opisanych w rozdziale pierwszym zostały w nim zastosowane. Proces miał charakter wieloetykietowy (ang. *multi-label*), co pozwalało na przypisanie jednemu akapitowi kilku różnych technik. W przypadkach niejednoznacznych - szczególnie przy dłuższych, wielowątkowych wypowiedziach - decyzje klasyfikacyjne opatrywano dodatkowym uzasadnieniem w formie notatek.

2.2. Wyniki anotacji manualnej

Spośród osiemnastu poddanych analizie akapitów, czternaście sklasyfikowano jako zawierające co najmniej jedną technikę perswazyjną. Pozostałe cztery uznano za neutralne pod względem retorycznym; obejmowały one: formułę proceduralną marszałka Sejmu (P01), formalne przedstawienie się mówcy (P04), przytoczenie danych liczbowych dotyczących skali pomocy świadczonej przez organizacje pozarządowe (P15) oraz sprawozdawczą relację z debaty w holenderskim parlamencie (P17).

⁸Piskorski, Jakub, Dimitar Dimitrov, Filip Dobranić, Marina Ernst, Jacek Haneczok, Ivan Koychev, Nikola Ljubešić, et al. 2025. SlavicNLP 2025 Shared Task: Detection and Classification of Persuasion Techniques in Parliamentary Debates and Social Media. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*. Vienna, Austria: Association for Computational Linguistics

Zidentyfikowane etykiety przyporządkowano do sześciu głównych kategorii taksonomicznych (uzupełnionych o dwie nowe techniki z edycji 2025), a następnie zestawiono ich częstotliwość występowania:

Kategoria	Liczba wystąpień
Manipulacyjne słownictwo	15
Atak na reputację	12
Uzasadnienie	8
Odwrócenie uwagi	6
Uproszczenie	4
Wezwanie	4

Najczęściej występującą w analizowanym materiale kategorią było manipulacyjne słownictwo. Kategoria ta opierała się przede wszystkim na nacechowanych emocjonalnie wyrażeniach, czyli *Loaded Language* (siedem akapitów), oraz na powtórzeniach, czyli *Repetition* (sześć akapitów), czego przykładem jest sformułowanie o „grze życiem kobiety” czy trzykrotne użycie wezwania „Rozmawiajmy” w konkluzji wystąpienia. Drugą pod względem częstotliwości kategorią był atak na reputację, przejawiający się głównie poprzez podważanie wiarygodności oraz formułowanie zarzutów hipokryzji wobec polityków i lekarzy powołujących się na klauzulę sumienia.

Trzecią pod względem częstotliwości kategorią było odwrócenie uwagi - w całości za sprawą *Appeal to Pity*, jednej z dwóch technik dodanych do taksonomii BSNLP w edycji 2025 (drugą jest *False Equivalence*, nieobecna w analizowanym materiale). *Appeal to Pity* zidentyfikowano sześciokrotnie, najwyraźniej w akapicie P13, w którym mówczynie przytacza historie konkretnych, zmarłych kobiet: Izabeli z Pszczyny, Agnieszki z Częstochowy i Doroty z Bochni. Klasyczne techniki tej samej kategorii - słomiana kukła czy zmiana tematu - nie wystąpiły ani razu, co można tłumaczyć specyfiką gatunkową tekstu: przemówienie z góry zaplanowane jako uzasadnienie własnego projektu ustawy ma inną strukturę i dynamikę retoryczną niż bezpośrednia polemika z oponentem, w której takie techniki stosowane są znacznie częściej. Częste odwołanie do litości sugeruje raczej spójną, emocjonalną strategię retoryczną całego wystąpienia niż próbę zmiany tematu, od którego mówczynie się nie uchyla.

Wyniki anotacji potwierdzają w większości zestawienie kategorii logicznych z rozdziału pierwszego. Dominujące w materiale manipulacyjne słownictwo - nacechowane emocjonalnie wyrażenia i powtórzenia - odpowiada temu, co w ujęciu Grice’a jest naruszeniem maksymy jakości i sposobu: mówczynie nie twierdzi wprost nieprawdy, ale dobór słownictwa i jego powtarzanie wywołują wrażenie silniejsze, niż wynikałoby z samej treści komunikatu. Podobnie atak na reputację, druga najczęstsza kategoria, odpowiada klasycznemu *ad hominem* oraz zarzutowi

hipokryzji, natomiast liczne odwołania do wartości i do strachu można - zgodnie z ujęciem Waltona - traktować jako neutralne schematy argumentacyjne, których uczciwość zależy od tego, czy towarzyszące im pytania krytyczne dałoby się w danym kontekście rozstrzygnąć na korzyść mówcy.

3. Analiza modeli językowych

3.1. Metodologia

Wybrany dokument, wraz z definicjami wszystkich dwudziestu pięciu technik, przekazano w ramach pojedynczego polecenia (ang. *prompt*) czterem publicznie dostępnym modelom językowym: GPT-5.6 Luna (dostępny w ChatGPT)⁹, Gemini 3.6 Flash¹⁰, DeepSeek R1¹¹ oraz Kimi K2.6 w trybie Instant¹². Każdy z modeli otrzymał identyczne instrukcje. Zadanie polegało na jednoczesnej ocenie wszystkich osiemnastu akapitów i wygenerowaniu spójnej odpowiedzi, w której każda decyzja klasyfikacyjna miała zostać uzasadniona w jednym lub dwóch zdaniach. Osadzenie pełnych definicji technik w treści polecenia częściowo nawiązuje do metodologii Jose i Greenstadt¹³, którzy w ramach zadania BSNLP 2025 zastosowali analogiczny zabieg w bardziej rozbudowanej formie - lecz tylko w drugim z dwóch podzadań konkursu, klasyfikacji konkretnych etykiet: osobno dla każdego akapitu, w dwóch przebiegach obejmujących połowę tagsetu naraz, z wymuszonym łańcuchem rozumowania i progiem pewności 0,99 przy ekstrakcji fragmentów, naprzemiennie na modelach gpt-4o-mini i o4-mini. W pierwszym podzadaniu konkursu - samej detekcji obecności techniki, bliższej pierwszemu pytaniu z anotacji w niniejszej pracy - użyły natomiast wyłącznie modelu o4-mini, bez łańcucha rozumowania i bez podziału na przebiegi, co według ich własnych ustaleń ograniczyło uzyskiwany recall. Wszystkie cztery modele użyte w niniejszej pracy natywnie wspierają tryb rozumowania (ang. *thinking/reasoning*) i z niego korzystały przy generowaniu odpowiedzi, mimo że polecenie nie narzucało im tego wprost. Zastosowane tu podejście - jeden prompt obejmujący cały dokument naraz, bez podziału na przebiegi, progu pewności ani wymuszonej struktury łańcucha rozumowania - pozostaje więc uproszczeniem drugiego podzadania metody Jose i Greenstadt przede wszystkim pod względem inżynierii promptu, a nie faktycznego zaangażowania modeli w rozumowanie nad tekstem. Nawiązuje ono również do wcześniejszych, niepublikowanych badań własnych,

⁹OpenAI. 2026. GPT-5.6 Luna (dostępny w ChatGPT) [duży model językowy]

¹⁰Google DeepMind. 2026. Gemini 3.6 Flash [duży model językowy]

¹¹DeepSeek. 2026. DeepSeek R1 [duży model językowy]

¹²Moonshot AI. 2026. Kimi K2.6, tryb Instant [duży model językowy]

¹³Jose, Julia, i Rachel Greenstadt. 2025. LLMs for Detection and Classification of Persuasion Techniques in Slavic Parliamentary Debates and Social Media Texts. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*, 202–216. Vienna, Austria: Association for Computational Linguistics

w których skuteczność modeli językowych weryfikowano na korpusie anglojęzycznym, jednak bez wykorzystania ustrukturyzowanej taksonomii¹⁴.

3.2. Porównanie wyników z anotacją referencyjną

Model	Zgodność z anotacją	Rozbieżności
ChatGPT	16/18 (89%)	2
Gemini	15/18 (83%)	3
DeepSeek	15/18 (83%)	3
Kimi	16/18 (89%)	2

Zgodność klasyfikacji modeli z anotacją referencyjną wyniosła od 83% do 89% - przy czym chodzi tu o zgodność, nie o poprawność: pojedyncza anotacja ręczna, jak zaznaczono we wnioskach, nie pretenduje do roli obiektywnego wzorca. Co istotne, w żadnym przypadku żaden model nie ocenił jako neutralnego akapitu, który anotator uznał za zawierający technikę perswazyjną. Wszystkie rozbieżności miały odwrotny kierunek: modele wskazywały technikę tam, gdzie anotator jej nie widział, zawsze w tych samych trzech akapitach (P04, P15, P17) - żaden model nie pomylił się poza tym zbiorem. Można to tłumaczyć na dwa sposoby - albo jako skłonność modeli do nadrozpoznawania perswazji w treściach czysto informacyjnych, albo jako możliwość, że pojedynczy anotator przeoczył subtelniejsze użycie technik akurat w tych fragmentach; rozstrzygnięcie między tymi wyjaśnieniami wymagałoby drugiego anotatora. Warto również zauważyć, że modele wykazywały wyższą zgodność wewnętrzną (między sobą) niż z anotacją referencyjną: dla szesnastu z osiemnastu akapitów wygenerowano identyczny werdykt u wszystkich czterech badanych systemów. Nie stoi to w sprzeczności z różną liczbą rozbieżności poszczególnych modeli w tabeli powyżej - z tych szesnastu jednomyślnych akapitów piętnaście to klasyfikacje zgodne z anotacją referencyjną, a jeden (P04) to rozbieżność, co do której wszystkie cztery modele są zgodne między sobą. Pozostałe dwa akapity, P15 i P17, to jedyne miejsca, w których modele nie są zgodne nawet między sobą (na każdym z nich trzy modele wskazują technikę, a jeden nie) - stąd różnice w łącznej liczbie rozbieżności poszczególnych modeli.

Znaczne rozbieżności względem anotacji referencyjnej zaobserwowano na poziomie przypisywania konkretnych etykiet. Systemy znacznie częściej sięgały po etykietę *Loaded Language* - wskazywano ją w niemal każdym akapicie uznanym za perswazyjny, podczas

¹⁴Kostecki, Dominik. 2025. Możliwości i ograniczenia sztucznej inteligencji w wykrywaniu manipulacji językowej

gdy w anotacji referencyjnej przypisano ją zaledwie w połowie przypadków. Zjawisko to jest wyraźnie widoczne na przykładzie akapitu P02, w którym mówczyni przytacza historię kobiety po odmowie wykonania legalnej aborcji przez szpital. W anotacji referencyjnej wskazano tu odwołanie do wartości, odwołanie do strachu oraz odwołanie do czasu (uzasadnione tym, że opowieść pada bezpośrednio po wzmiance o wcześniejszym przesunięciu debaty przez marszałka Sejmu, co nadaje jej wydźwięk pilności); wszystkie cztery modele niezależnie od siebie przypisały mu wspólną parę etykiet - odwołanie do litości (*Appeal to Pity*) oraz manipulacyjne słownictwo (*Loaded Language*), przy czym dwa z czterech modeli dodały do tej pary jeszcze trzecią etykietę (odpowiednio odwołanie do strachu i podważanie wiarygodności) - a żaden z nich nie wskazał odwołania do czasu. Modele zgodziły się więc ze sobą nawzajem bardziej niż z anotacją referencyjną, co sugeruje wspólne obciążenie w stronę technik łatwo rozpoznawalnych leksykalnie kosztem tych, które - jak zauważa Grice w kontekście implikatur konwersacyjnych - wymagają wykroczenia poza dosłowną treść zdania i uwzględnienia szerszego kontekstu wypowiedzi.

Podsumowanie

Przeprowadzone w rozdziale pierwszym zestawienie taksonomii BSNLP z klasycznymi kategoriami logicznymi w dużej mierze potwierdziło początkowe założenia - większość technik uwzględnionych w BSNLP ma swoje bezpośrednie odpowiedniki wśród znanych błędów we wnioskowaniu (takich jak *ad hominem* czy odwołanie do autorytetu). Z kolei anotacja manualna, opisana w rozdziale drugim, wykazała, że w analizowanym materiale dominowało manipulacyjne słownictwo, atak na reputację oraz uzasadnienie, podczas gdy odwrócenie uwagi wystąpiło w umiarkowanym stopniu - wyłącznie za sprawą nowo dodanej w 2025 roku techniki odwołania do litości - a uproszczenie i wezwanie do działania należały do najrzadszych kategorii.

Porównanie anotacji referencyjnej z klasyfikacją przeprowadzoną przez cztery modele językowe, przedstawione w rozdziale trzecim, ujawniło wyraźny wzorzec: żaden z badanych systemów nie pominął akapitu ocenionego przez anotatora jako perswazyjny, za to wszystkie wykazały skłonność do wskazywania technik w akapitach uznanych za neutralne i czysto informacyjne oraz do nadmiarowego stosowania etykiety *Loaded Language*. Nie da się przy tym rozstrzygnąć jednoznacznie, czy to modele nadrozpoznają perswazję, czy pojedynczy anotator przeoczył coś w tych fragmentach - stąd waga postulatu drugiego anotatora, o którym mowa niżej.

Niniejsze badanie ma istotne ograniczenia metodologiczne. Analizie poddano wyłącznie jeden dokument i wystąpienie pojedynczej osoby, co nie pozwala na uogólnienie wniosków na całość polskiego dyskursu parlamentarnego. Anotacji referencyjnej dokonał samodzielnie autor pracy - to nie tylko kwestia braku drugiego, niezależnego anotatora, ale też ryzyka nieświadomego obciążenia własnymi oczekiwaniami badawczymi, którego nie da się wykluczyć przy samoanotacji. Jak wskazują sami twórcy taksonomii BSNLP, zgodność ocen między profesjonalnymi, niezależnymi anotatorami w tego typu zadaniach jest stosunkowo niska ($\alpha \approx 0,34$)¹⁵ - innymi słowy, inny anotator pracujący nad tym samym tekstem mógłby części akapitów przypisać inne etykiety, nie popełniając przy tym błędu. Przyjęte w tej pracy etykiety należy więc traktować jako jedną z kilku możliwych, obronionych klasyfikacji, a nie jako jedyny poprawny wzorzec.

¹⁵Piskorski, Jakub, Nicolas Stefanovitch, Giovanni Da San Martino, i Preslav Nakov. 2023. SemEval-2023 Task 3: Detecting the Category, the Framing, and the Persuasion Techniques in Online News in a Multi-lingual Setup. W *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, 2343–2361. Toronto, Canada: Association for Computational Linguistics

Ograniczenia dotyczą też strony eksperymentu z modelami językowymi. Testowanie miało charakter jednorazowy i nie uwzględniało weryfikacji powtarzalności odpowiedzi przy ponownym przetwarzaniu tego samego tekstu. Względem drugiego podzadania metody Jose i Greenstadt¹⁶, które posłużyło za wzór, było to podejście uproszczone przede wszystkim pod względem inżynierii promptu: bez wymuszonego progu pewności przy wskazywaniu technik i bez podziału promptu na przebiegi obejmujące mniejsze podzbiory tagsetu. Wszystkie cztery testowane modele natywnie wspierają jednak tryb myślenia i korzystały z niego przy generowaniu odpowiedzi, mimo że prompt tego nie wymuszał. Skłonności do nadrozpoznawania technik i faworyzowania etykiety *Loaded Language*, opisaney w rozdziale trzecim, nie da się więc łatwo wytłumaczyć brakiem namysłu ze strony modeli - warto ją zbadać dalej właśnie dlatego, że pojawiła się mimo rozumowania nad tekstem, nie z jego braku.

Naturalnym kierunkiem dalszych prac badawczych byłoby zatem powtórzenie zaprezentowanej procedury na obszerniejszym korpusie dokumentów, z uwzględnieniem niezależnej weryfikacji przez drugiego anotatora w celu wyznaczenia miary zgodności. Wskazane byłoby również sprawdzenie, czy zaobserwowana tendencja modeli do nadużywania etykiety *Loaded Language* utrzymuje się w przypadku zastosowania alternatywnych wariantów formułowania poleceń (ang. *prompt engineering*), a także czy powtarza się przy użyciu najpotężniejszych, flagowych wariantów tych samych rodzin modeli (np. GPT-5.6 Sol, Gemini 3.1 Pro, Claude Opus 5 czy Kimi K3) zamiast ich szybszych, darmowo dostępnych odmian zastosowanych w niniejszym eksperymencie.

¹⁶Jose, Julia, i Rachel Greenstadt. 2025. LLMs for Detection and Classification of Persuasion Techniques in Slavic Parliamentary Debates and Social Media Texts. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*, 202–216. Vienna, Austria: Association for Computational Linguistics

Bibliografia

- Arystoteles. 1990. *O dowodach sofistycznych*. Warszawa: Wydawnictwo Naukowe PWN.
- DeepSeek. 2026. DeepSeek R1 [duży model językowy].
- Google DeepMind. 2026. Gemini 3.6 Flash [duży model językowy].
- Grice, H. Paul. 1975. Logic and Conversation. W *Speech Acts*, red. Peter Cole i Jerry L. Morgan, 3:41–58. Syntax and Semantics. New York: Academic Press.
- Hamblin, Charles Leonard. 1970. *Fallacies*. London: Methuen.
- Hołówka, Teresa. 1998. *Błędy, spory, argumenty: szkice z logiki stosowanej*. Warszawa: Wydział Filozofii i Socjologii Uniwersytetu Warszawskiego.
- Jose, Julia, i Rachel Greenstadt. 2025. LLMs for Detection and Classification of Persuasion Techniques in Slavic Parliamentary Debates and Social Media Texts. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*, 202–216. Vienna, Austria: Association for Computational Linguistics.
- Kostecki, Dominik. 2025. Możliwości i ograniczenia sztucznej inteligencji w wykrywaniu manipulacji językowej.
- Moonshot AI. 2026. Kimi K2.6, tryb Instant [duży model językowy].
- OpenAI. 2026. GPT-5.6 Luna (dostępny w ChatGPT) [duży model językowy].
- Piskorski, Jakub, Dimitar Dimitrov, Filip Dobranić, Marina Ernst, Jacek Haneczok, Ivan Koychev, Nikola Ljubešić, et al. 2025. SlavicNLP 2025 Shared Task: Detection and Classification of Persuasion Techniques in Parliamentary Debates and Social Media. W *Proceedings of the 10th Workshop on Slavic Natural Language Processing (Slavic NLP 2025)*. Vienna, Austria: Association for Computational Linguistics.
- Piskorski, Jakub, Nicolas Stefanovitch, Giovanni Da San Martino, i Preslav Nakov. 2023. SemEval-2023 Task 3: Detecting the Category, the Framing, and the Persuasion Techniques in Online News in a Multi-lingual Setup. W *Proceedings of the 17th International Workshop on Semantic Evaluation (SemEval-2023)*, 2343–2361. Toronto, Canada: Association for Computational Linguistics.
- Walton, Douglas N., Christopher Reed, i Fabrizio Macagno. 2008. *Argumentation Schemes*. Cambridge: Cambridge University Press.